RESUA

Un asistente para consultar avistamientos

Ingeniería de Software · EAM · Armenia, Quindío

Proyecto de Ingeniería de Software de EAM para registrar y buscar avistamientos de especies silvestres en Armenia, Quindío.



EAM · Ingeniería de Software

Made with GAMMA

ARQUITECTURA DE CONSULTA

RESUA convierte una pregunta en una respuesta trazable

01 recepción

La persona registra un avistamiento o pregunta cómo usar la plataforma.

02 orquestación

El sistema clasifica la solicitud, decide el siguiente paso y responde con evidencia.

03 entorno

El prototipo se desarrolla de forma incremental en un notebook de Google Colab.



Bitácora de campo y trazabilidad técnica

Made with GAMMA

CONTROL DE EJECUCIÓN

El flujo separa al modelo de las decisiones críticas

El modelo clasifica y propone; la lógica de control valida condiciones antes de autorizar herramientas o salidas.

01

01 · validar

Saneamiento de texto e inspección de límites de entrada.

02

02 · clasificar

Inferencia con esquema JSON estructurado y tipado.

03

03 · enrutar

Aclaración inmediata, escalamiento humano o pase directo.

04

04 · consultar

Validación de código de estado o recuperación en base RAG.

05

05 · auditar

Emisión de respuesta final con registro de latencia y huellas.

pipeline lineal · control imperativo sobre la ejecución del llm

Made with GAMMA

CONTRATO DE ENTRADA

La clasificación estructurada evita respuestas ambiguas

esquema json

Campos estrictos requeridos en cada clasificación:

- Categoría y prioridad
- Resumen de intención
- Datos faltantes
- Bandera de revisión humana
- Nivel de confianza

aclaración

Cuando faltan parámetros o la consulta resulta ambigua, el sistema no adivina ni asume datos: detiene la cadena y solicita información puntual al usuario.

MÁXIMA PRIORIDAD

revisión humana

Modificar, eliminar o aprobar registros, solicitar credenciales o reportar emergencias deriva de inmediato a un operador humano, anulando cualquier aclaración.

La bandera de revisión humana se evalúa antes de ejecutar cualquier herramienta.

Made with GAMMA

HERRAMIENTA DETERMINISTA

La herramienta de estados es limitada y de solo lectura

Propuesta y verificación de código

El modelo puede proponer consultar un código como AVS-1001. El código debe cumplir el patrón AVS-0000.

Presencia textual obligatoria

El código debe aparecer en el texto original y existir en la base ficticia.

Bloqueo de mutaciones

El sistema valida argumentos y bloquea modificaciones, eliminaciones o aprobaciones.



Garantía de solo lectura y validación léxica

Made with GAMMA

RECUPERACIÓN AUMENTADA

El RAG responde solo con fragmentos recuperados

Toda respuesta documental exige citas explícitas que coincidan con la evidencia devuelta por la base vectorial.

01

corpus

Documentos segmentados en fragmentos manejables.

02

embeddings

Vectores multilingües de 384 dimensiones.

03

supabase

Índice pgvector con similitud coseno.

04

recuperación

Filtro de fragmentos relevantes con umbral.

05

generación

Groq redacta la respuesta con citas y limitaciones.

Regla de oro: si un fragmento no fue recuperado, el asistente no puede citarlo ni afirmar su contenido.

Made with GAMMA

BENCHMARK DE RECUPERACIÓN

La evaluación favorece una solución rápida y consistente

Estrategia evaluada	Precisión / Recall@3	Latencia media	Comportamiento general
A_semantica ✓ elegida	Competitiva y estable	**La menor latencia**	Desempeño uniforme entre consultas
B_hibrida_rrf	Mejoras marginales	Latencia media-alta	Ganancias inconsistentes entre grupos
C_hibrida_rerank	Sin ventaja sistemática	Mayor latencia	Costo computacional no justificado

Decisión: Se adoptó **A_semantica** por su rapidez y estabilidad en el corpus de prueba; las opciones B y C agregaban sobrecarga sin aportar mejoras consistentes.

Made with GAMMA

MARCO DEL PROTOTIPO

Seguridad, trazabilidad y límites definen el prototipo

Entradas no confiables

Tanto las preguntas del usuario como los textos recuperados se procesan como entradas sin privilegios.

Registro completo de auditoría

Cada consulta almacena modelo, prompts, tiempo de respuesta, conteo de tokens y huellas del corpus.

Alcance didáctico actual

El corpus es acotado, los avistamientos son ficticios y no existe aún conexión directa con la base en producción.



Registro auditable y delimitación del sistema

Made with GAMMA